

OCR Template Pipeline

한국어 서류 OCR 템플릿 기반 자동 추출 시스템

대상 문서: 기본직접지불금 지급대상자 등록신청서 (농업인용)

Capstone Project

2026.04

1. 프로젝트 개요

본 시스템은 한국 농업 보조금 신청서(기본직접지불금 지급대상자 등록신청서)의 필기/인쇄 내용을 자동으로 추출하는 OCR 파이프라인이다.

수기 작성된 대량의 신청서를 일괄 처리하여 엑셀로 출력하되, 악필 등으로 인식이 불확실한 항목은 관리자가 웹 UI에서 직접 검수할 수 있다.

핵심 기능

- 웹 기반 템플릿 편집기: PDF 위에 바운딩 박스를 그려 OCR 영역 지정
- 배치 OCR 파이프라인: 수백 건의 PDF를 GPU 배치로 일괄 처리
- 신뢰도 기반 자동/검수 분류: 임계점 미달 항목만 관리자 검수
- 웹 검수 UI: crop 이미지와 OCR 결과를 보면서 승인/수정
- 엑셀 출력: 4개 시트 (인적사항/가족관계/검수항목/원본결과)
- 개인정보 마스킹: 주민등록번호, 계좌번호 자동 마스킹

2. 시스템 아키텍처

전체 흐름은 4단계로 구성된다:

[1단계] 템플릿 편집기 (ocr_template_editor.html)

PDF를 열고 각 필드의 바운딩 박스를 마우스로 지정한다.
53개 프리셋 필드를 제공하며, JSON 템플릿으로 저장한다.

[2단계] Crop + OCR 파이프라인 (run_pipeline.py)

템플릿 좌표로 PDF에서 필드를 crop하고,
ko-trocr 모델로 GPU 배치 추론을 실행한다.

[3단계] 검증 + 분류 (validator.py)

필드타입별 정규식 검증과 신뢰도 기반 상태 분류를 수행한다.
결과를 엑셀 4시트로 출력한다.

[4단계] 관리자 검수 (review_server.py)

검수 필요 항목을 웹 UI에서 확인/수정 후 엑셀을 재생성한다.

3. 디렉토리 구조

경로	역할	라인수
template_editor/ocr_template_editor.html	템플릿 편집기 (독립 HTML, 서버 불필요)	970
template_editor/app.py	Flask 서버 (선택적, PDF 렌더링용)	124
template_editor/field_presets.py	53개 프리셋 필드 정의	91
ocr_pipeline/run_pipeline.py	메인 CLI, 배치 오케스트레이션	208
ocr_pipeline/crop_generator.py	템플릿 기반 crop 이미지 생성	116
ocr_pipeline/ocr_engine.py	ko-trocr 배치 OCR + checkbox 판정	252
ocr_pipeline/validator.py	필드타입 검증 + 마스킹	168
ocr_pipeline/excel_writer.py	엑셀 4시트 출력	219
ocr_pipeline/review_server.py	Flask 검수 UI 서버	138
ocr_pipeline/templates/review.html	관리자 검수 웹 UI	283
template/	저장된 템플릿 JSON	-
input/	입력 PDF 파일	-
output/	출력 엑셀 파일	-
work/	작업 디렉토리 (crop, JSONL 등)	-

4. 하드웨어 요구사항 및 GPU 메모리

OCR 모델: ddbokki/ko-trocr

항목	값
모델 아키텍처	TrOCR (ViT encoder + KR-BERT decoder)
파라미터 수	213.7M
라이선스	Apache-2.0
입력	crop 이미지 (RGB)
출력	텍스트 + 신뢰도

GPU 메모리 사용량 (VRAM)

구성	VRAM 사용량	비고
모델 로드 (FP32)	0.80 GB	모델 가중치만
모델 로드 (FP16)	0.40 GB	half precision
추론 batch=32 (FP32)	~1.2 GB	가중치 + 활성화
추론 batch=64 (FP32)	~1.5 GB	가중치 + 활성화
추론 batch=128 (FP32)	~2.0 GB	대량 배치 처리

본 시스템은 NVIDIA A100 80GB 환경에서 개발/테스트되었다.

모델 크기가 작아 (213.7M) 일반적인 GPU (4GB+ VRAM)에서도 충분히 동작한다.

CUDA 미지원 환경에서는 CPU 모드로 자동 전환되나, 처리 속도가 크게 저하된다.

최소/권장 사양

항목	최소 사양	권장 사양
GPU	GTX 1060 6GB	RTX 3060 이상 / A100
VRAM	2 GB	8 GB+
RAM	8 GB	16 GB+
Python	3.10+	3.10
PyTorch	2.0+	2.10+ (CUDA 12)
디스크	2 GB (모델)	5 GB+ (모델 + 작업)

5. 소프트웨어 의존성

패키지	버전	용도	라이선스
torch	2.10+	딥러닝 프레임워크	BSD-3
transformers	5.7+	HuggingFace 모델 로딩	Apache-2.0
PyMuPDF (fitz)	1.27+	PDF 렌더링/이미지 변환	AGPL-3.0
Pillow	12.1+	이미지 처리	HPND
openpyxl	3.1+	엑셀 생성	MIT
opencv-python	4.13+	체크박스/서명 판정	Apache-2.0
Flask	3.1+	검수 UI 서버	BSD-3
tqdm	4.0+	진행률 표시	MIT/MPL
fpdf2	2.8+	PDF 문서 생성	LGPL-3.0

6. 필드 타입 및 처리 방식

field_type	처리 방식	검증 규칙	예시
korean_name	ko-trocr OCR	한글 2~5자, 숫자 포함시 오류	홍길동
resident_number	ko-trocr OCR	6-7자리 형식, 마스킹 저장	800101-1*****
phone	ko-trocr OCR	전화번호 패턴 검사	010-1234-5678
account	ko-trocr OCR	숫자/은행명 혼합 허용	농협 123-456
address	ko-trocr OCR	5자 미만시 검수	경기도 파주시...
number_text	ko-trocr OCR	숫자/하이픈 허용	123456789
date	ko-trocr OCR	날짜 형식 정규화	2026-04-29
date_or_birth	ko-trocr OCR	6/8자리 허용	1980-01-01
relation	ko-trocr OCR	관계 사전 검증	배우자
text	ko-trocr OCR	최소 검증	임의 문자열
checkbox	OpenCV 흑색비율	true/false/unknown	true
signature	픽셀 밀도 분석	present/absent	present

7. 신뢰도 및 검수 체계

신뢰도 범위	상태	처리
≥ 0.80	ok	자동 승인
0.50 ~ 0.80	needs_review	관리자 검수 필요
< 0.50	low_confidence	관리자 검수 필수

주민등록번호, 계좌번호는 신뢰도와 무관하게 항상 needs_review로 분류된다.
체크박스는 이미지 내 흑색 픽셀 비율로 판정하며, 애매한 경우 unknown 처리된다.

상태 코드

status	의미
ok	정상 추출, 검증 통과
needs_review	관리자 검수 필요
missing	필수 필드인데 값 없음
low_confidence	신뢰도 50% 미만
invalid_format	형식 오류 (정규식 불일치)
ocr_failed	OCR 실패 (이미지 열기 실패 등)
multiple_candidates	후보 2개 이상, 점수 차이 작음
unknown	판정 불가

8. 사용법

Step 1: 템플릿 생성

ocr_template_editor.html을 브라우저에서 열어 PDF를 로드한다.
 마우스 드래그로 각 필드의 바운딩 박스를 그리고,
 프리셋에서 field_key/type/group을 선택한다.
 완성된 템플릿을 JSON으로 저장한다.

Step 2: OCR 파이프라인 실행

```
python run_pipeline.py \
  --template template/page1_template.json \
  --input input/ \
  --output output/result.xlsx \
  --device cuda:0 \
  --batch-size 32
```

Step 3: 검수 UI

```
python review_server.py --work-dir work
```

브라우저에서 localhost:5001 접속.
 crop 이미지와 OCR 결과를 확인하고 승인/수정한다.
 키보드 단축키: Enter(승인+다음), Tab(다음), Esc(판독불가)

Step 4: 엑셀 재생성

검수 완료 후 웹 UI에서 '엑셀 재생성' 버튼을 클릭하면
 검수 결과가 반영된 최종 엑셀이 output/ 폴더에 생성된다.

CLI 옵션

옵션	기본값	설명
--template	(필수)	템플릿 JSON 경로
--input	(필수)	입력 PDF 디렉토리
--output	output/result.xlsx	출력 엑셀 경로
--device	cuda:0	GPU 디바이스
--batch-size	32	GPU 배치 크기
--model	ddobokki/ko-trocr	OCR 모델
--resume	False	이전 결과 이어서 처리
--no-mask	False	개인정보 마스킹 비활성화
--cleanup	False	처리 후 crop 이미지 삭제

9. 배치 처리 전략

대량 처리 시 다음과 같은 최적화가 적용된다:

1. 모든 PDF의 모든 crop을 하나의 큐에 모아 GPU 배치 추론
(PDF별로 따로 처리하지 않음 -> GPU 활용도 극대화)
2. batch_size 조절 가능 (기본 32, A100에서 128까지 가능)
3. 중간 결과를 JSONL로 스트리밍 저장
(중단 후 --resume 옵션으로 이어서 처리)
4. tqdm 진행률 표시
5. 이미 처리된 request_id는 자동 스킵

예상 처리 속도

GPU	batch_size	초당 crop 수	100건 PDF (40필드/건) 예상
A100 80GB	64	~120	~33초
RTX 3060	16	~40	~100초
CPU only	1	~2	~33분

10. 개인정보 처리

본 시스템은 주민등록번호, 계좌번호, 주소, 전화번호 등 민감 정보를 처리한다.
다음과 같은 보호 조치가 적용된다:

1. 엑셀 저장 시 주민등록번호 뒷자리 마스킹 (800101-1*****)
2. 계좌번호 일부 마스킹
3. raw_ocr_results 시트에만 원본 저장 (접근 제한 필요)
4. --cleanup 옵션으로 처리 후 crop 이미지 자동 삭제
5. --no-mask 옵션은 관리자 전용 (마스킹 해제)